

Rachunek prawdopodobieństwa i statystyka

Niezależność \bar{X} i S^2

Założmy, że zmienne losowe X_1, \dots, X_n są niezależne i podlegają rozkładowi $N(\mu, \sigma^2)$ każda. Określmy dwie nowe zmienne losowe \bar{X}, S^2 jako

$$\bar{X} = \frac{1}{n} \sum_{k=1}^n X_k, \quad S^2 = \frac{1}{n} \sum_{k=1}^n (X_k - \bar{X})^2. \quad (1)$$

Używając funkcji generujących momentów (MGFs-ów), stwierdzamy iż

Twierdzenie 1. $\bar{X} \sim N(\mu, \sigma^2/n)$.

Dowód. Z notatki 5, tw. 1 wynika, że:

$$M_{\bar{X}}(t) = \prod_{k=1}^n M_{X_k}\left(\frac{t}{n}\right) = \exp\left(n\mu u + \frac{n\sigma^2 u^2}{2}\right)\Big|_{u=t/n} = \exp\left(t\mu + \frac{\sigma^2 t^2}{2n}\right) \sim N\left(\mu, \frac{\sigma^2}{n}\right)$$

□

Zanim zajmiemy się zmienną S^2 , wprowadźmy nową zmienną losową $S_\mu^2 = \frac{1}{n} \sum_{k=1}^n (X_k - \mu)^2$. Po niewielkim przekształceniu, znajdujemy iż $\frac{nS_\mu^2}{\sigma^2} = \sum_{k=1}^n \left(\frac{X_k - \mu}{\sigma}\right)^2 \equiv \chi^2(n)$ ¹. Znajdziemy teraz związek pomiędzy S_μ^2 a S^2 .

Twierdzenie 2.

$$S_\mu^2 = S^2 + (\bar{X} - \mu)^2. \quad (2)$$

Dowód.

$$\begin{aligned} n \cdot S_\mu^2 &= \sum_{k=1}^n (X_k - \mu)^2 = \sum_{k=1}^n (X_k - \bar{X} + \bar{X} - \mu)^2 = \\ &= \sum_{k=1}^n (X_k - \bar{X})^2 + n \cdot (\bar{X} - \mu)^2 + 2 \cdot \sum_{k=1}^n (\bar{X} - \mu)(X_k - \bar{X}). \end{aligned}$$

Sprawdzamy, że

$$\sum_{k=1}^n (\bar{X} - \mu)(X_k - \bar{X}) = (\bar{X} - \mu) \cdot \sum_{k=1}^n (X_k - \bar{X}) = (\bar{X} - \mu) \cdot \left(\sum_{k=1}^n X_k - n \cdot \bar{X}\right) = 0,$$

co kończy dowód twierdzenia. □

UWAGA: Nieformalnie możemy zapisać **twierdzenie 1** w postaci $\chi^2(n) \equiv (\text{pewien_rozkład}) + \chi^2(1)$. Gdyby **pewien_rozkład** i $\chi^2(1)$ były niezależne, to moglibyśmy powiedzieć coś o **pewnym rozkładzie** – czyli o rozkładzie S^2 (Twierdzenie 1. z notatki 5.) Twierdzenie 1. z bieżącej notatki można bowiem przepisać w postaci

$$\frac{nS_\mu^2}{\sigma^2} = \frac{nS^2}{\sigma^2} + \left(\frac{\bar{X} - \mu}{\sigma/\sqrt{n}}\right)^2. \quad (3)$$

Po lewej stronie powyższego równania rozpoznajemy rozkład $\chi^2(n)$, drugi składnik prawej strony podlega rozkładowi $\chi^2(1)$.

¹Lista 6., zadanie 8.

Niezależność \bar{X} oraz S^2

Wprowadzamy nowe zmienne Y_k następująco:

$$Y_1 = \bar{X}, \quad Y_k = X_k - \bar{X}, \quad (k = 2, \dots, n). \quad (4)$$

Ponieważ zmienne X_1, \dots, X_n są niezależne więc n -wymiarowa gęstość $f_{X_1, \dots, X_n}(x_1, \dots, x_n)$ wyraża się wzorem

$$f_{X_1, \dots, X_n}(x_1, \dots, x_n) = (2\pi)^{-n/2} \sigma^{-n} \prod_{k=1}^n \exp \left\{ -\frac{1}{2} \left(\frac{x_k - \mu}{\sigma} \right)^2 \right\} = (2\pi)^{-n/2} \sigma^{-n} \exp \left\{ -\frac{1}{2} \sum_{k=1}^n \left(\frac{x_k - \mu}{\sigma} \right)^2 \right\}. \quad (5)$$

Odwrócenie wzorów (??) daje

$$\begin{aligned} X_k &= \bar{X} + Y_k = Y_1 + Y_k \quad (k = 2, \dots, n), \\ nY_1 &= X_1 + \dots + X_n = X_1 + (Y_1 + Y_2) + \dots + (Y_1 + Y_{n-1}) + (Y_1 + Y_n), \text{ czyli} \\ X_1 &= Y_1 - Y_2 - \dots - Y_n. \end{aligned} \quad (6)$$

Wyznacznik Jacobianu odwrócenia (??) daje wartość $n \cdot 2$. Wzór (??) można zatem przepisać, – w nowym układzie współrzędnych – w postaci

$$g_{Y_1, \dots, Y_n}(y_1, \dots, y_n) = n \cdot (2\pi)^{-n/2} \sigma^{-n} \exp \left\{ -\frac{1}{2} \sum_{k=1}^n \left(\frac{x_k - \mu}{\sigma} \right)^2 \right\}, \quad (7)$$

gdzie w miejsce x_k należy podstawić wzory (??). Tymczasowo, nie dokonujemy tego podstawienia, wzory byłyby nazbyt złożone. Zajmiemy się tylko wykładnikiem wzoru (??), bez czynnika $-1/2$. Uwzględniając wzór (??) możemy wspomniany wykładnik przedstawić w postaci

$$\frac{nS_\mu^2}{\sigma^2} = \sum_{k=1}^n \left(\frac{X_k - \mu}{\sigma} \right)^2 = \sum_{k=1}^n \left(\frac{X_k - \bar{X}}{\sigma} \right)^2 + \left(\frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \right)^2 = \frac{nS^2}{\sigma^2} + \chi^2(1). \quad (8)$$

Drugi składnik po prawej stronie jest zapisany nieformalnie.³

S^2 jest funkcją Y_2, \dots, Y_n .

Rozpatrzmy $nS^2 = \sum_{k=1}^n (X_k - \bar{X})^2 = (X_1 - \bar{X})^2 + \sum_{k=2}^n (X_k - \bar{X})^2$. Uwzględniając wzory (??) można je (to równanie) przepisać w postaci

$$nS^2 = \sum_{k=1}^n (X_k - \bar{X})^2 = \left(\sum_{k=2}^n Y_k \right)^2 + \sum_{k=2}^n Y_k^2. \quad (9)$$

S^2 oraz \bar{X} są niezależne.

Pamiętając o tym, że $Y_1 \equiv \bar{X}$ i podstawiając równość (??) do równania (??) otrzymujemy

$$\begin{aligned} K &= n \cdot (2\pi)^{-n/2} \sigma^{-n}, \\ g_{Y_1, \dots, Y_n}(y_1, \dots, y_n) &= K \exp \left\{ -\frac{1}{2} \sum_{k=1}^n \left(\frac{x_k - \mu}{\sigma} \right)^2 \right\} \stackrel{(8)}{=} \\ &\stackrel{(8)}{=} K \exp \left\{ -\frac{1}{2} \left(\frac{nS_\mu^2}{\sigma^2} \right) \right\} = K \exp \left\{ -\frac{1}{2} \left(\frac{nS^2}{\sigma^2} \right) \right\} \cdot \exp \left\{ -\frac{1}{2} \left(\frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \right)^2 \right\}. \end{aligned} \quad (10)$$

To dowodzi następującego twierdzenia

²Por. zadanie 5. z listy 1.

³Por. twierdzenie ??.

Twierdzenie 3. Zmienne losowe \bar{X} oraz S^2 są niezależne. Inaczej: zmienne losowe Y_1 oraz (Y_2, \dots, Y_n) są niezależne.

Równanie (??) można przepisać – w języku funkcji tworzących momenty – następująco:

$$(1 - 2t)^{-n/2} = M_{\frac{nS^2}{\sigma^2}}(t) = M_{\frac{nS^2}{\sigma^2}}(t) \cdot (1 - 2t)^{-1/2}.$$

Stąd wynika

Twierdzenie 4. $\frac{nS^2}{\sigma^2} \sim \chi^2(n-1) \equiv \text{Gamma}\left(\frac{1}{2}, \frac{n-1}{2}\right)$.

Oczywiście, twierdzenia ?? oraz ?? są prawdziwe przy założeniu, że zmienne losowe X_1, \dots, X_n są niezależne i podlegają rozkładowi $N(\mu, \sigma^2)$ każda.

Wielowymiarowy rozkład normalny.

Definicja 1. Mówimy, że zmienna losowa $(X_1, \dots, X_n)^T$ podlega n -wymiarowemu rozkładowi normalnemu – w skrócie $X \sim N(\mu, \Sigma)$ – wtedy i tylko wtedy gdy

$$f_X(x) = f_{X_1, \dots, X_n}(x_1, \dots, x_n) = \frac{1}{(2\pi)^{n/2} |\Sigma|^{1/2}} \exp \left[-\frac{1}{2} (X - \mu)^T \Sigma^{-1} (X - \mu) \right]. \quad (11)$$

UWAGI:

1. Wektor $\mu = [\mu_1, \dots, \mu_n]^T \in \mathbb{R}^n$. Liczbę μ_k nazywamy wartością oczekiwaną jednowymiarowej zmiennej brzegowej X_k .
2. Symetryczną, dodatnio określoną macierz $\Sigma = (s_{ij})_{i,j=1}^n \in \mathbb{R}^{n \times n}$ nazywamy macierzą wariancji-kowariancji. Liczbę s_{ii} nazywamy wariancją zmiennej X_i , liczbę s_{ij} – kowariancją zmiennych X_i, X_j .
3. Symbol $|\Sigma|$ oznacza wyznacznik macierzy Σ .
4. Dla $n = 1$ wzór (??) upraszcza się do postaci

$$f_X(x) = f_{X_1(x_1)} = \frac{1}{(\sqrt{2\pi}) \sigma_1} \exp \left[-\frac{1}{2} (X_1 - \mu_1)^T (\sigma_1^2)^{-1} (X_1 - \mu_1) \right].$$

5. Wzór (3) z notatki 5. ilustruje wypadek $n = 2$.
6. Symetryczna macierz $M \in \mathbb{R}^{n \times n}$ jest nazywana macierzą dodatnio określoną jedynie wtedy gdy $\forall x \in \mathbb{R}^n \ x^T M x \geq 0$, natomiast równość zachodzi jedynie dla $x = \mathbb{O}$. Macierz dodatnio określona ma n wartości własnych $\lambda_k > 0$, w szczególności jest to macierz odwracalna.

Niech macierz $A \in \mathbb{R}^n$ będzie macierzą odwracalną, a zmienna losowa X niech ma rozkład $N(\mu, \Sigma)$. Rozważmy zmienną losową $Y = AX$, to znaczy Y jest obrazem zmiennej losowej X względem przekształcenia liniowego A . Przy tych założeniach prawdziwe jest poniższe

Twierdzenie 5.

$$Y \sim N(A\mu, A\Sigma A^T).$$

Dowód. Zajmijmy się wykładnikiem wzoru (??), bez czynnika $-1/2$. Ponieważ macierz jest odwracalna, więc $X = A^{-1}Y$, co podstawieniu do wykładnika daje

$$(X - \mu)^T \Sigma^{-1} (X - \mu) = (A^{-1}Y - \mu)^T \Sigma^{-1} (A^{-1}Y - \mu) = (A^{-1}(Y - A\mu))^T \Sigma^{-1} (A^{-1}(Y - A\mu)) = (*)$$

Korzystając z zależności $(SU)^T = U^T S^T$ oraz $(SU)^{-1} = U^{-1} S^{-1}$ mamy

$$(*) = (Y - A\mu)^T (A^{-1})^T \Sigma^{-1} A^{-1} (Y - A\mu) = (Y - A\mu)^T ((A\Sigma A^T))^{-1} (Y - A\mu).$$

Zauważamy podobieństwo otrzymanego wzoru do wykładnika wzoru (??). Obydwa wzory mają postać $z^T M^{-1} z$.

Przejdźmy teraz do Jacobianu przekształcenia $X = A^{-1}Y$. Jeżeli elementy macierzy A^{-1} oznaczymy symbolem b_{ij} , to $X_i = \sum_{k=1}^n b_{ik} Y_k$. Stąd $\frac{\partial X_i}{\partial Y_j} = b_{ij}$, czyli $J = |A^{-1}| = \frac{1}{|A|}$. Przejście do zmiennej Y we wzorze (??) daje

$$f_Y(y) = f_{Y_1, \dots, Y_n}(y_1, \dots, y_n) = \frac{1}{(2\pi)^{n/2} |\Sigma|^{1/2} |A|} \exp \left[-\frac{1}{2} (Y - A\mu)^T ((A\Sigma A^T))^{-1} (Y - A\mu) \right].$$

Uwzględniając równość $|A\Sigma A^T| = |A| |\Sigma| |A^T| = |\Sigma| |A|^2$ otrzymujemy tezę twierdzenia.

□

←

Witold Karczewski