

## Generator liczb losowych z rozkładu $N(0, 1)$

### Przykład:

Założmy, że mamy do dyspozycji generator liczb losowych z rozkładu  $U[0, 1]$  i wylosowaliśmy dwie wartości  $u_1, u_2$ . Dwuwymiarowa zmienna losowa  $(U_1, U_2)$  ma zatem rozkład o gęstości  $f_{U_1, U_2}(u_1, u_2) = 1$  dla  $((u_1, u_2) \in [0, 1] \times [0, 1])$ . Rozważmy nowe zmienne  $Y_1 = -2\ln U_1$ ,  $Y_2 = 2\pi U_2$ . Oczywiście  $Y_1 \in [0, \infty)$  oraz  $Y_2 \in [0, 2\pi)$ . Interpretując  $Y_1, Y_2$  jako współrzędne biegunowe punktu na płaszczyźnie można powiedzieć iż losujemy kwadrat promienia i argument punktu. Wyznamy gęstość  $f_{Y_1, Y_2}(y_1, y_2)$  zmiennej  $(Y_1, Y_2)$ .

$$\left\{ \begin{array}{l} U_1 = \exp\left(-\frac{Y_1}{2}\right) \\ U_2 = \frac{Y_2}{2\pi} \end{array} \right., \text{ skąd } \text{abs}(J) = \text{abs} \begin{vmatrix} -\frac{1}{2} \exp\left(-\frac{Y_1}{2}\right) & 0 \\ 0 & \frac{1}{2\pi} \end{vmatrix} = \frac{1}{4 \cdot \pi} \exp\left(-\frac{Y_1}{2}\right). \quad (1)$$

W powyższym wzorze chcemy policzyć wartość bezwzględną z wyznacznika Jacobianu. Niestety, obydwie operacje (wartość bezwzględna i wyznacznik) oznaczane są często tym samym znakiem  $|\cdot|$ . Wskutek tego:  $\text{abs}(\det(A)) \equiv ||A||$  – co z kolei mogłoby sugerować, że mówimy o **normie** macierzy  $A$ .

Dla gęstości  $f_{Y_1, Y_2}(y_1, y_2)$  mamy zatem wzór

$$f_{Y_1, Y_2}(y_1, y_2) = \frac{1}{4 \cdot \pi} \exp\left(-\frac{Y_1}{2}\right). \quad (2)$$

Od współrzędnych biegunowych  $(Y_1, Y_2)$  przejdźmy teraz do współrzędnych kartezjańskich  $(X_1, X_2)$ , to znaczy

$$\left\{ \begin{array}{l} X_1 = \sqrt{Y_1} \cos Y_2 \\ X_2 = \sqrt{Y_1} \sin Y_2 \end{array} \right., \text{ i stąd } J = \begin{vmatrix} \frac{\cos Y_2}{2\sqrt{Y_1}} & -\sqrt{Y_1} \sin Y_2 \\ \frac{\sin Y_2}{2\sqrt{Y_1}} & \sqrt{Y_1} \cos Y_2 \end{vmatrix} = \frac{1}{2}. \quad (3)$$

Kończymy przekształcenia dwiema uwagami:

1. Wyznaczony powyżej Jacobian należy **ODWRÓCIĆ**. Zwyczajowo liczymy Jacobian “starych” zmiennych względem “nowych”. Tutaj: wygodniej jest wyznaczyć odwrotność Jacobianu “nowych” zmiennych względem “starych” zmiennych.
2. Korzystamy również z zależności:  $Y_1 = X_1^2 + X_2^2$  <sup>a</sup>.

Wynik końcowy  $\equiv$  gęstość  $f_{X_1, X_2}(x_1, x_2)$  ma postać:

$$f_{X_1, X_2}(x_1, x_2) = \frac{1}{2\pi} \exp\left(-\frac{x_1^2 + x_2^2}{2}\right) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{x_1^2}{2}\right) \times \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{x_2^2}{2}\right), \quad (4)$$

co oznacza, że zmienne  $X_1, X_2$  są niezależne i mają rozkład  $N(0, 1)$  każda.

---

<sup>a</sup>(wzór (3))

## Różne przybliżenia wariancji

Zakładamy, że dane są niezależne obserwacje pochodzące z tego samego rozkładu  $N(\mu, \sigma^2)$ . Wiadomo,<sup>1</sup> że zmienna  $\frac{nS_\mu^2}{\sigma^2}$  ma rozkład  $\chi^2(n)$  a także<sup>2</sup>  $\frac{nS_n^2}{\sigma^2} \sim \chi^2(n-1)$ .

Wspomnijmy również, że  $\chi^2(k) \equiv \text{Gamma}(1/2, k/2)$ . Stąd, dla rozkładu  $\chi^2(k)$ :  $M_{\chi^2(k)}(t) = (1-2t)^{-k/2}$ . To umożliwia sformułowanie – w miarę prostego do dowodu – twierdzenia

**Twierdzenie 1.** *Jeżeli zmienna losowa  $X \sim \chi^2(k)$ , to  $E(X) = k$  oraz  $V(X) = 2k$ .*

Rozpatrzmy trzy estymatory wariancji  $\sigma^2$ , mianowicie  $S_{n-1}^2 = \frac{1}{n-1} \sum_{k=1}^n (X_k - \bar{X})^2$ ,  $S_n^2 = \frac{1}{n} \sum_{k=1}^n (X_k - \bar{X})^2$  oraz  $S_{n+1}^2 = \frac{1}{n+1} \sum_{k=1}^n (X_k - \bar{X})^2$ . Z początkowej uwagi wynika, że zmienne  $\frac{(n-1)S_{n-1}^2}{\sigma^2}$ ,  $\frac{nS_n^2}{\sigma^2}$ ,  $\frac{(n+1)S_{n+1}^2}{\sigma^2}$  mają rozkład  $\chi^2(n-1)$  każda.

Wartość oczekiwana  $E\left(\frac{nS_n^2}{\sigma^2}\right) = n-1$ . Stąd,  $E(S_n^2) = \frac{n-1}{n} \sigma^2$ . Wartość oczekiwana przybliżenia  $S_n^2$  jest zatem różna od wartości przybliżanego parametru  $\sigma^2$ . O takim estymatorze mówimy, że jest **estymatorem obciążonym**. Jeżeli  $n \rightarrow \infty$ , to  $E(S_n^2) \rightarrow \sigma^2$ . Mówimy wówczas, że  $S_n^2$  jest estymatorem **asymptotycznie nieobciążonym** parametru  $\sigma^2$ .

Ponieważ  $S_{n-1}^2 = \frac{n}{n-1} S_n^2$ , więc  $E(S_{n-1}^2) = \sigma^2$ . Mówimy, że  $S_{n-1}^2$  jest **nieobciążonym estymatorem** parametru  $\sigma^2$ . Podobnie  $S_{n+1}^2 = \frac{n}{n+1} S_n^2$  czyli  $E(S_{n+1}^2) = \frac{n-1}{n+1} \sigma^2$  ( $S_{n+1}^2$  jest estymatorem obciążonym dla  $\sigma^2$ ). Najlepszym estymatorem (uwzględniając wartość oczekiwaną) jest zatem  $S_{n-1}^2$ , najgorszym  $S_{n+1}^2$ .

Porównajmy teraz wariancje rozpatrywanych estymatorów. Wiemy, że  $\frac{nS_n^2}{\sigma^2} \sim \chi^2(n-1)$ . Stąd wynika, że  $V(S_n^2) = \frac{2(n-1)}{n^2} \sigma^4$ ,  $V(S_{n-1}^2) = \frac{2(n-1)}{(n-1)^2} \sigma^4$  oraz  $V(S_{n+1}^2) = \frac{2(n-1)}{(n+1)^2} \sigma^4$ . Im mniejsza wariancja, tym bardziej zmienna losowa jest “stabilna”. Najlepszym estymatorem (kierując się wariancją) jest  $S_{n+1}^2$ , najgorszym  $S_{n-1}^2$ .

## [Popularne|Ulubione] wzory i rozkłady

1. Załóżmy, że zmienne losowe  $X, Y$  są niezależne i podlegają rozkładom  $X \sim \chi^2(n)$ ,  $Y \sim \chi^2(k)$ . Wówczas zmienna losowa  $Z = X + Y$  podlega rozkładowi  $Z \sim \chi^2(n+k)$ .
2. Załóżmy, że zmienna  $X$  podlega rozkładowi  $N(\mu, \sigma^2)$ . Niech dodatkowo  $Y = \frac{X - \mu}{\sigma}$ . Zachodzi FAKT:  $X \sim N(\mu, \sigma^2) \iff Y \sim N(0, 1)$ .
3.  $\text{Gamma}(1/2, n/2) \equiv \chi^2(n)$ .
4. Załóżmy, że zmienne  $X_1, \dots, X_n$  są niezależne i podlegają rozkładowi  $N(\mu, \sigma^2)$  każda. Wówczas zmienna  $Z = \sum_{k=1}^n \left(\frac{X_k - \mu}{\sigma}\right)^2$  ma rozkład  $\chi^2(n)$ .
5. Niezależne zmienne  $X, Y$  mają rozkłady  $X \sim \chi^2(k)$ ,  $Y \sim \chi^2(l)$  odpowiednio. Mówimy, że zmienna  $F(k, l) = \frac{X}{Y} \cdot \frac{l}{k}$  ma rozkład F-Fishera z  $(k, l)$  stopniami swobody.
6. Niezależne zmienne  $X, Y$  mają rozkłady  $X \sim N(0, 1)$ ,  $Y \sim \chi^2(k)$  odpowiednio. Mówimy, że zmienna  $t(k) = \frac{X}{\sqrt{Y/k}}$  ma rozkład t-Studenta z  $k$  stopniami swobody.

<sup>1</sup>Notatka 6, wzór (3).

<sup>2</sup>Notatka 6, tw. 4.

7. Intuicja: iloraz niezależnych i normalizowanych rozkładów  $\chi^2$  to rozkład F-Fishera zaś iloraz standardowego rozkładu normalnego i pierwiastka normalizowanego rozkładu  $\chi^2$  to rozkład  $t$ -Studenta.
8. Załóżmy, że zmienne  $X_1, \dots, X_n$  są niezależne i podlegają rozkładowi  $N(\mu, \sigma^2)$  każda. Niech dodatkowo  $S_\mu^2 = \frac{1}{n} \sum_{k=1}^n (X_k - \mu)^2$ . Wówczas  $\frac{nS_\mu^2}{\sigma^2} \sim \chi^2(n)$ .
9. Załóżmy, że zmienne  $X_1, \dots, X_n$  są niezależne i podlegają rozkładowi  $N(\mu, \sigma^2)$  każda. Niech dodatkowo  $S^2 = \frac{1}{n} \sum_{k=1}^n (X_k - \bar{X})^2$ . Wówczas  $\frac{nS^2}{\sigma^2} \sim \chi^2(n-1)$ .
10. ... tysiąc i jeden wzór (jak w orientalnych baśniach).

Witold Karczewski